

Aula 6

Aula passada

- Limitante da união
- Método do primeiro momento
- Lei dos grandes números (fraca e forte)
- Erro e confiança

Aula de hoje

- Método de Monte Carlo
- Estimando somatórios
- Calculando erro
- Estimando π
- Erro de π
- Integração de Monte Carlo
- Monte Carlo Ray Tracing

Método de Monte Carlo

- Classe de algoritmos baseado em amostragem aleatória repetida
 - obter solução aproximada para problemas determinísticos
- Ideia central: grande número de amostras repetidas acabam revelando a solução
 - no limite, amostras dão a solução

Lei dos grandes números!

$$M_n = \frac{1}{n} \sum_{i=1}^n X_i \quad P\left[\lim_{n \rightarrow \infty} M_n = \mu\right] = 1 \xrightarrow{\text{E}[X_i], \forall i}$$

- Arcabouço teórico para método de Monte Carlo

Calculando Soma

- Calcular o valor de um somatório (problema da aula 1)
 - N (número de parcelas) é muito grande
 - calcular valor de cada parcela é fácil

$$G_N = \sum_{i=1}^N g(i)$$

parcela

- Como usar aleatoriedade para resolver (aproximar) este somatório?
- Usando valor esperado!



- Seja X uma v.a. uniforme em $[1, N]$

- $P[X = i] = 1/N$ para $i=1, \dots, N$

$$E[g(X)] = \sum_{i=1}^N P[X=i]g(i) = \frac{1}{N} \sum_{i=1}^N g(i) = \frac{G_N}{N}$$

Fazendo com que não dependa de i → uniforme

Calculando Soma

- Logo, temos que $G_N = N E[g(X)] \rightarrow$ Equações determinística
pois N é um parâmetro
- Podemos agora estimar $E[g(X)]$. Como?

Gerando amostras, fazendo a média!

- Seja X_i sequência iid de v.a. uniforme $[1, N]$

- escolher um valor para n (número de amostras)

$$M_n = \frac{1}{n} \sum_{i=1}^n g(X_i) \leftarrow \begin{array}{l} \text{Média amostral com } n \text{ amostras} \\ \text{Estimador para } E \end{array}$$

- Temos que $E[M_n] = E[g(X)]$, para todo n

O estimador
não possui viés

- $M_n \rightarrow E[g(X)]$ quando $n \rightarrow \infty$ (pela lei dos grds números)

- M_n é estimador de $E[g(X)]$, logo N^*M_n é estimador para G_N

1º passo de
Monte Carlo:
escrever o
que se
quer
calcular por
um E .

Arestas no Facebook

- Quantas arestas tem a rede de amizade do Facebook?
 - função indicadora de aresta, $g(i, j) = 1$ se existe aresta entre perfil i e j
 - número de perfis $n_p = 2 \cdot 10^9$

$$T = \sum_{i=1}^{n_p} \sum_{j=i+1}^{n_p} g(i, j) \quad \leftarrow T = \text{número de arestas}$$

Todos os pares

Problema: somatório tem $\sim 10^{18}$ termos!

- Como construir um método de Monte Carlo para obter um valor aproximado para T ?

Enumarar os pares

Arestas no Facebook

- Seja $Z = (i, j)$ uma v.a. uniforme no conjunto de pares com n_p perfis

$\mathcal{P} \rightarrow$ conjunto de pares de perfis

$$\mathbb{E}[g(i, j)] = \sum_{(x, y) \in \mathcal{P}} P[x=i \text{ e } y=j] g(x, y)$$

- $N = n_p(n_p - 1)/2 \rightarrow$ número total de pares

$N = \binom{n_p}{2}$

$$E[g(Z)] = \sum_{i=1}^{n_p} \sum_{j=i+1}^{n_p} \frac{1}{N} g(i, j) = \frac{1}{N} T$$

\hookrightarrow Sempre conectar com um \mathbb{E}

$$\begin{aligned} &= \sum_{i=1}^{n_p} \sum_{j \neq i}^{n_p} \frac{1}{N} g(i, j) \\ &= \frac{1}{N} \sum_{(i, j) \in \mathcal{E}} g(i, j) \end{aligned}$$

$$T = N \cdot \mathbb{E}[g(Z)]$$

- Seja Z_i sequência iid de v.a. uniforme sobre pares

$$M_n = \frac{1}{n} \sum_{i=1}^n g(Z_i)$$

\hookrightarrow i-ésimo par escolhido de maneira uniforme do conjunto de pares

Média amostral com n amostras, estima $E[g(Z)]$

NÃO HÁ NADA ALERTÓRIO

- Logo T é aproximado por $M_n * N$

Jogando Paciência

- Qual é a fração de vezes que um algoritmo determinístico A vence o jogo de paciência?
 - vencer depende apenas da permutação das cartas do baralho (não há aleatoriedade)
- Seja s uma permutação das cartas
 - $f_A(s) = 1$ se algoritmo A vence com permutação s , 0 c.c.
- N = número total de permutações das cartas, $N = 52!$

$$F_A = \frac{1}{N} \sum_{s=1}^N f_A(s)$$

Uma maneira óbvia e aviltar a fração de vezes em que o algoritmo vence

Queremos estimar esta fração

Problema: somatório tem $52!$ termos!

- Monte Carlo to the rescue!

Jogando Paciência

- Seja S uma v.a. uniforme em $[1, N]$ que representa uma permutação
 - uniforme entre todas possíveis permutações das cartas

$$E[f_A(S)] = \sum_{s=1}^N \frac{1}{N} f_A(s) = \frac{1}{N} \sum_{s=1}^N f_A(s) = F_A$$

*Etapa 1:
Trocar um
por um E*

- Valor esperado já é a fração que queremos!
- Seja S_i sequência iid de v.a. uniforme em $[1, N]$

- S_i é uma permutação das cartas

$$M_n = \frac{1}{n} \sum_{i=1}^n f_A(S_i)$$

→ permutações aleatórias

← Média amostral da fração de vezes que algoritmo vence

- Logo, F_A é aproximado por M_n

Etapa 2: Estimar E

Vantagens e Desvantagens



- Trocar $G_N = \sum_{i=1}^N g(i)$ por $M_n = \frac{1}{n} \sum_{i=1}^n g(X_i)$

• Quando esta ideia é boa?

- Comparação entre N e n
- Se N for pequeno, ideia não é boa
 - podemos calcular G_N diretamente
- Se calcular $g(\cdot)$ é muito caro, boa ideia mesmo quando N pequeno
- Se $g(i)$ for muito “errática”, ideia não é boa
 - ex. um valor de $g(i)$ é maior que todo o resto da soma
 - estimador pode ser muito ruim se n não for muito grande
- Qualidade da aproximação depende de N , n , $g()$

m possui 2 papéis:
- calcular o estimador
- controlar a qualidade do estimador

complicado
outlier

Calculando o Erro

- Podemos usar Chebyshev para calcular n
 - para precisão ϵ e confiança β , temos

$$P[M_n \in [\mu - \epsilon, \mu + \epsilon]] > 1 - \frac{\sigma^2}{\epsilon^2 n} = \beta$$

precisão ↕

↳ confiança

- onde μ e σ^2 são o valor esperado e variância da v.a. que será aproximada pelo estimador μ não é um problema para calcular n , mas σ^2 é algo que precisar ser estimado
- onde $g()$ é geralmente uma função indicadora (para contar coisas) e X é uma v.a. uniforme nos valores que g pode assumir
 - 1. Estimar σ^2
 - 2. Estimar n
- **Problema:** muitas vezes não sabemos σ^2
 - temos que estimar com o estimador!

$$G_N = \sum_{i=1}^N g^{(i)}$$

Erro da Paciência

- Seja $F_A = 0.1$ fração de vezes que algoritmo A vence
 - S é v.a. uniforme nas permutações
 - $\mu = E[f_A(S)] = 0.1$, $\sigma^2 = \text{Var}[f_A(S)] = 0.1 * 0.9 = 0.09$
 - Supor $\epsilon = 10^{-4}$ e $\beta = 0.99$

$$P[M_n \in [\mu - \epsilon, \mu + \epsilon]] > 1 - \frac{\sigma^2}{\epsilon^2 n} = \beta$$


$$1 - \frac{0.09}{(10^{-4})^2 n} = 0.99 \rightarrow n = 9 * 10^8$$

Trocamos um \sum
de 10^{68} parcelas
por um de 10^8

- Muito, muito menor do que $52! \sim 10^{68}$
parcelas com uma confiança muito alta

Calculando π

- Como estimar o valor de π ?
 - ou qualquer outro valor que tenha relação com geométrica
- Ideia
 - Escrever π como relação entre áreas
 - Usar Monte Carlo para estimar relação




- $A_q = \text{Área do quadrado} = 1$
- $A_c = \text{Área do círculo} = \pi r^2 = \pi/4$
- $\pi = 4 * A_c / A_q$
- Estimar A_c / A_q



Calculando π

- Ideias para estimar A_c / A_q ?
- Gerar n pontos uniforme no quadrado
- Fração do pontos que estão dentro do círculo!



$$E[g(x,y)] = \frac{A_c}{A_q}$$

uniforme no quadrado

- Seja X e Y duas v.a. uniformes contínuas em $[0, 1]$
- Seja $g(x, y)$ indicadora do ponto (x, y) estar dentro do círculo
 - $g(x,y) = 1$ se $(x-0.5)^2 + (y-0.5)^2 \leq 1$
- Temos $E[g(x, y)] = A_c / A_q = \pi/4$
- Como estimar $E[g(x, y)]$?

Calculando π

- Seja X_i, Y_i sequência iid uniforme em $[0,1]$
 - v.a. contínua

$$M_n = \frac{1}{n} \sum_{i=1}^n g(X_i, Y_i) \leftarrow \text{Fração de pontos que estão dentro do círculo}$$

- M_n converge para $\pi/4$ (pela lei dos grds números)
- Logo π pode ser estimado por $4 * M_n$

O Erro de π

- Podemos usar Chebyshev para calcular n
 - para precisão ϵ e confiança β , temos

$$P[M_n \in [\mu - \epsilon, \mu + \epsilon]] > 1 - \frac{\sigma^2}{\epsilon^2 n} = \beta$$

$\pi/4 \quad \downarrow \quad \begin{matrix} \text{precisão} \\ \rightarrow E[g(X,Y)] = \frac{A_c}{A_g} = \pi/4 \Rightarrow p \end{matrix}$

confiança
* note que não precisamos de μ para fazer este cálculo, mas precisamos de σ^2

- $\mu = E[g(X,Y)] = P[g(X,Y) = 1] = \pi/4$

- $\sigma^2 = \text{Var}[g(X,Y)] = \pi/4 (1 - \pi/4)$

Variância da indicadora:
 $p \cdot (n-p)$

- Não sabemos π mas σ^2 de uma v.a. indicadora tem valor máximo quando $p = 1/2 \rightarrow \sigma^2 = 1/4$

- Supor $\epsilon = 10^{-6}$ e $\beta = 0.99$

- então temos que $n = 2.5 * 10^{16}$

O m cálculo do com $p = 1/2$ certamente satisfaz a confiança mínima, pois σ^2 é máximo para $p = 1/2$.

MSE e SEM

- Mean Squared Error (MSE)

- medida clássica para erro de preditores ou estimadores
- $MSE(\phi') = E_{\phi'}[(\phi' - \phi)^2]$, onde ϕ' é o estimador e ϕ o valor a ser estimado

$\xrightarrow{\text{estimador}}$ $\xrightarrow{\text{mão-aleatório}}$

$\xrightarrow{\text{aleatório}}$

$\xrightarrow{\text{média amostral}}$

- Seja M_n (média amostral) o estimador para o valor μ

- $MSE(M_n) = \text{Var}(M_n) = \sigma^2/n$

- Standard Error of the Mean (SEM)

- medida de erro relativo

$$\sqrt{\frac{\sigma^2}{n}} = \sqrt{MSE(M_n)}$$

- $SEM(M_n) = \sigma/\sqrt{n} = \sqrt{MSE(M_n)}$

- Para qualquer M_n , sempre decresce como \sqrt{n}

- não é muito rápido!


$\xrightarrow{\text{SEM decresce muito devagar}}$

SEM de π

- $\text{SEM}(M_n) = \sigma/\sqrt{n}$
- Erro relativo = $|4M_n - \pi| / \pi$ $\approx y$

- Teoria e prática estão bem de acordo!
- Repare $1/\sqrt{n}$ é devagar !

Para um erro relativo de 10^{-2} precisamos de 10^4 amostras




Integração Numérica

- Encontrar a integral definida de uma função

$$x=b$$
$$\int_{x=a}^b f(x) dx$$

- **Problema:** função pode não ser integrável (ou muito difícil de integrar)!



- **Solução:** integração numérica
- Conjunto de algoritmos para calcular valor da integral
 - muito usado na física, química, engenharia, etc

- Abordagem via Monte Carlo é uma classe de algoritmos
 - **Monte Carlo integration**

Integração de Monte Carlo

- Generalização da ideia de computar o valor de π
- Calcular razão entre área de “baixo da curva” (integral) e de um “quadrado” (limites de integração)
- Estimar este valor usando amostras uniformes
- Supor $0 \leq f(x) \leq 1$, para x em $[0, 1]$

$$I = \int_{x=0}^{x=1} f(x) dx$$

- Definir função indicadora para ponto de baixo da curva
 - $g(x, y) = 1$ se $f(x) \leq y$, e zero c.c.
- Seja X, Y v.a. contínuas uniformes em $[0, 1]$

Integração de Monte Carlo

- Valor esperado

$$E[g(X, Y)] = \int_{x=0}^{x=1} \int_{y=0}^{y=1} f_{XY}(x, y) g(x, y) dx dy$$

- $f_{XY}(x, y) = f_X(x) f_Y(y) = 1$ (densidade conjunta de duas v.a. contínuas uniformes e independentes)

- $E[g(X, Y)] = \frac{\text{área embaixo da curva}}{\text{área do quadrado } [0,1] \times [0,1]} = I$

- X e Y tem domínio uniforme
- Como estimar $E[g(X, Y)]$?

- Seja X_i, Y_i sequência iid de uniformes em $[0, 1]$

$$M_n = \frac{1}{n} \sum_{i=1}^n g(X_i, Y_i) \quad \begin{array}{l} \text{indicadora do ponto } (x_i, y_i) \text{ abaixo da curva} \\ \leftarrow \text{Fração de pontos que estão baixo da curva} \end{array}$$

Integração de Monte Carlo

- Método alternativo: relacionar valor esperado diretamente com valor da integral

$x=1 \rightarrow$ funções que quero integrar

$$I = \int_{x=0}^{x=1} f(x) dx$$

- Seja X v.a. contínua uniforme em $[0, 1]$

$$E[f(X)] = \int_{x=0}^{x=1} f_X(x) f(x) dx = \int_{x=0}^{x=1} f(x) dx = I$$

- Pois $f_X(x) = 1$ (densidade da v.a. uniforme em $[0,1]$)
- Como estimar $E[f(X)]$?
- Seja X_i sequência iid uniforme em $[0, 1]$

Converge para valor esperado
em n (lei dos grds números)

$$M_n = \frac{1}{n} \sum_{i=1}^n f(X_i)$$

Generalização

- Funciona para qualquer limite de integração, e qualquer número de dimensões

- grande vantagem da abordagem Monte Carlo

$$I = \int_{\omega} f(\vec{x}) d\vec{x}$$

$$V = \int_{\omega} d\vec{x}$$

→ volume dentro dos limites de integração ω

↳ integral múltipla com k dimensões


- onde x é um ponto em um espaço de k dimensões, ω um “pedaço” fechado deste espaço, e V é o volume de ω
 - Seja X_i uma sequência iid de v.a. uniforme no espaço ω

- X_i tem k dimensões

- Temos

$$M_n = \frac{1}{n} \sum_{i=1}^n f(\vec{X}_i)$$


converge para I/V quando $n \rightarrow \infty$



Monte Carlo Ray Tracing

- Integração de Monte Carlo em Computação Gráfica
- **Problema:** determinar cor (intensidade de luz) em um pixel em uma cena construída - *Renderização*

Integral formulation (“rendering equation”)



$$R = \int_{\Omega} L(y) dy$$

↳ caminho


← Resolvida numericamente
usando método de Monte Carlo

- Integrate over all possible light paths y ← Muitos, muitos caminhos!

Monte Carlo Ray Tracing

$$\int_{\Omega} L(y) dy = E \left[\frac{L(Y)}{\text{pdf}[Y]} \right]$$

uniforme
↑
constante



Advantage of Monte-Carlo


- Good compromise between cost and precision:
 $\epsilon = O(1/\sqrt{N})$
in contrast, integration by e.g. trapezoid rule has an error of $\epsilon = O(1/N^{2/d})$, for d dimensions

Se diferenciam no número de amostras utilizadas na renderização
computacional

Disadvantage of Monte-Carlo

- Output is random → A renderização depende das realizações'

Estimando π



Seja $X \sim U[0,1]$ e $Y \sim U[0,1]$ e $g(x,y)$ uma variável aleatória indicadora tal que

$$g(x,y) = \begin{cases} 1, & \text{se } x^2 + y^2 \leq 1 \\ 0, & \text{caso contrário} \end{cases}$$

Desta forma, $g(x,y)$ pode ser modelada como uma Bernoulli cujo parâmetro p é a fração A_c / A_g . Logo,

$$\mathbb{E}[g(x,y)] = p = \frac{A_c}{A_g} = \frac{\pi r^2}{(2r)^2} = \frac{\pi}{4}$$


Por Monte Carlo, podemos estimar $\mathbb{E}[g(x,y)]$ por amostragem

$$\mathbb{E}[g(x,y)] \approx \frac{1}{n} \sum_{i=1}^n g(x_i, y_i) = M_n$$

Portanto,

$$\boxed{\pi = 4M_n}$$

Integracão de Monte Carlo - Método da Fracção



Queremos calcular

$$I = \int_a^b f(x) dx$$

$$f_x(n) = \frac{1}{b-a}$$

Seja $X \sim U[a, b]$, $y \sim \max f(x) \cdot U[0, 1]$

$$g(x, y) = \begin{cases} 1, & \text{se } f(x) \leq y \\ 0, & \text{caso contrário} \end{cases}$$

Desta forma, $g(x, y)$ pode ser modelada como uma Bernoulli cujo parâmetro p é a fração I/Ar . Assim,

$$\mathbb{E}[g(x, y)] = p = \frac{I}{Ar} = \frac{I}{(b-a) \cdot \max f(x)}$$

Por Monte Carlo, podemos estimar $\mathbb{E}[g(x, y)] \approx \frac{1}{n} \sum_{i=1}^n g(x_i, y_i) = \bar{I}_n$

Logo,

$$I = (b-a) \cdot \max f(x) \cdot \bar{I}_n$$

Integracão de Monte Carlo - Método Direto

Queremos calcular $I = \int_a^b f(x) dx$.

Seja $X \sim U[a, b] \rightarrow f_X(x) = \frac{1}{b-a}$. Obtemos o valor esperado de $f(x)$ em relação a f_X temos

$$\mathbb{E}[f(x)] = \int_a^b f_X(x) \cdot f(x) dx = \int_a^b \frac{1}{b-a} \cdot f(x) dx = \frac{I}{b-a}$$

Por outro lado, $\mathbb{E}[f(x)]$ pode ser estimado por monte carlo:

$$M_n = \frac{1}{n} \sum_{i=1}^n f(x_i) \approx \mathbb{E}[f(x)]$$

Logo,

$$I \approx (b-a) M_n$$