

# Aula 8

## Aula passada


- Gerando amostras de v.a. discretas
- Gerando Geométrica
- Método da transformada inversa
- Gerando Binomial
- Gerando permutações

## Aula de hoje

- Método da rejeição (*rejection sampling*)
- Exemplos
- *Importance Sampling*
- Exemplos
- Generalização


# Rejection Sampling

- Técnica fundamental para geração de amostras aleatórias
  - usada em Markov Chain Monte Carlo (veremos depois)
- Ideia: usar distribuição conhecida para gerar amostras de outra distribuição, mais complicada
- Sejam  $X$  e  $Y$  duas v.a. com distribuições  $p_x$  e  $q_x$ , definidas no mesmo suporte  $\rightarrow$  Se  $p_x \geq 0$ , então  $p_y \geq 0$ 
  - $p_x = P[X = x]$ ,  $q_x = P[Y = y]$
- Assuma que  $q_x \leq c p_x$  para alguma constante  $c$  e todo  $x$ 
  - ou seja,  $c p_x$  é uma função envelope para  $q_x$
- Supor que sabemos gerar amostras para v.a.  $X$ 
  - ex. método da transformada inversa
- Como usar isto para gerar amostras para v.a.  $Y$ ?



# Rejection Sampling

- Algoritmo (proposto por von Neumann) um dos métodos mais do NC
- 1) Gerar valor para  $i$  a partir de  $p_x$   $i \sim p_x$
- 2) Gerar  $u$  uniforme(0,  $c p_i$ ) contínua, usando o  $i$  gerado
- 3) Se  $u < q_i$ , retorna  $i$ , caso contrário vai para 1)  
 $P[Y=i]$  → rejeitar a amostra
- Graficamente



- Algoritmo pode *rejeitar* amostra gerada de X várias vezes
  - *rejection sampling*
  - Rejeita com probabilidade proporcional a diferença de  $p_x$  e  $q_x$

$i$  com probabilidade  $p_x - q_x$  Figueiredo 2018

# Rejection Sampling Funciona

- Mostrar que algoritmo funciona
  - ou seja, algoritmo gera amostra  $i$  com probabilidade  $q_i$
- Considere um valor  $i$  e o evento *aceitar*
$$P[X=i, \text{aceitar}] = P[X=i] P[\text{aceitar} | X=i] = p_i q_i / (c p_i) = q_i/c$$
- Probabilidade de aceitar (por prob. total)
$$P[\text{aceitar}] = \sum_i P[X=i, \text{aceitar}] = \sum_j \frac{q_j}{c} = \frac{1}{c}$$
- Ao final de cada rodada, algoritmo aceita com prob.  $1/c$
- Temos então

$$P[\underbrace{X=i}_{\text{prob. do algoritmo retornar } i} | \text{aceitar}] = \frac{P[X=i, \text{aceitar}]}{P[\text{aceitar}]} = \frac{\frac{q_i}{c}}{\frac{1}{c}} = q_i = P[Y=i]$$


# Rodadas de *Rejection Sampling*

- A cada rodada, algoritmo aceita com prob.  $1/c$   $\Rightarrow P[\text{aceitar}]$
- Número de rodadas até aceitar é aleatório. Distribuição?
  - Geométrica com parâmetro  $1/c$   $\Rightarrow P$
  - valor esperado  $= c = \frac{1}{P}$  *Na média, precisamos de c rodadas para gerar uma amostra*
  - complexidade de caso médio para cada amostra *amostra*
- Escolha do valor para  $c$  é muito importante
  - menor valor tal que  $q_x \leq c p_x$  para todo  $x$  *que é um envelope que mais se aproxima de  $q_x$*
  - Valor depende da “distância” entre  $q_x$  e  $p_x$
  - se muito diferentes, pode demandar  $c$  muito grande

Técnica funciona também  
com v.a. contínua

# Exemplo

- Dado moeda enviesada, cara com prob  $p > \frac{1}{2}$
- Como gerar moeda sem viés?




- Moeda enviesada

- Moeda honesta

- Encontrar constante  $c$  tal que  $q_x \leq c p_x$

- $c(1-p) = \frac{1}{2} \rightarrow c = 1/(2(1-p))$

- 1) Gerar valor para  $i = \{C, K\}$  a partir de  $p_x$  (moeda enviesada)
- 2) Gerar  $u$  uniforme( $0, c p_i$ ) contínua, usando o  $i$  gerado
- 3) Se  $u < q_i$ , retorna  $i$ , caso contrário vai para 1)



# Exemplo 2

- Gerar amostras da v.a.  $Y$  contínua com densidade  $f_Y(x) = 20x(1-x)^3$ ,  $0 < x < 1$
  - Usando método da rejeição. Que distribuição proponente?
    - uniforme[0,1],  $g_x(x) = 1$ ,  $0 < x < 1$
  - Determinar  $c$  tal que  $f(x) \leq c g(x)$  para  $0 < x < 1$
  - Ideia: encontrar máximo de  $f(x)/g(x)$  →  *$g(x)$  é cte, então basta derivar  $f(x)$* 
    - derivar, igualar a zero, resolver para  $x$ , encontrar valor
    - máximo em  $x = 1/4$ ,  $c = 135/64$   
 $f(1/4) = 135/64$
- 1) Gerar valor para  $x$  a partir de  $g(x)$  (uniforme[0,1])
  - 2) Gerar  $u$  uniforme(0,  $c g(x)$ ) contínua, usando o  $x$  gerado
  - 3) Se  $u < f(x)$ , retorna  $x$ , caso contrário vai para 1)

# Cenário Problemático

- Algoritmo de Monte Carlo é estimador universal
  - média amostral converge para valor esperado
- **Problema:** variância do estimador pode ser muito alta!
  - muitas, muitas amostras serão necessárias
- Exemplo  $G_N = N \cdot M_n$ 
$$G_N = \sum_{i=1}^N g(i) \quad M_n = \frac{1}{n} \sum_{i=1}^n g(X_i), X_i \sim \text{Unif}(1, N)$$
  - $g(i)$  é pequena (ou zero) para muitos valores de  $i$ , e grande para poucos valores
  - Teremos que gerar muitas amostras para “acertar” os valores importantes de  $g(i)$
  - Ideias para atacar o problema?

# Importance Sampling

Devemos tentar gerar os elementos das regiões que possuem

→ Técnica de  
variance  
reduction

- Amostrar com probabilidade diferente da original *mais*
  - uniforme no exemplo anterior
- Amostrar com maior probabilidade região mais importante para o problema em questão → Pode evitá-lo  
para as regiões de grande massa
- *importance sampling*
- Compensar pelo aumento desta probabilidade
- Usar método de Monte Carlo em problema reformulado
  - com novas funções de distribuição que compensem o viés
- **Objetivo:** reduzir a variância do estimador *Quero gerar mais amostras de regiões importantes sem gerar viés*
  - isto nem sempre ocorre, pois se exagerar demais vai ter que compensar com mais amostras!
  - técnica tem que ser usada com cuidado

# Importance Sampling

o problema da uniforme é dar a mesma probabilidade para TODAS as parcelas

- Seja  $X$  uma v.a. uniforme( $1, N$ )

$$E[g(X)] = \sum_{i=1}^N P[X=i]g(i) = \frac{1}{N} \sum_{i=1}^N g(i) = \frac{G_N}{N}$$

U.a. uniforme      quero estimar

- Seja  $Y$  v.a. com distribuição dada por  $h(i) > 0$  para todo  $i$

$$E_h\left[\frac{g(Y)}{h(Y)}\right] = \sum_{i=1}^N \frac{g(i)}{h(i)} h(i) = \sum_{i=1}^N g(i) = G_N$$

$\hookrightarrow$  usamos  $h$  de forma que eu saiba gerar suas amostras

Boa notícia! Podemos escolher  $h(i)$

Estou interessado NESTA DISTRIBUIÇÃO

- Podemos estimar  $G_N$  estimando o valor esperado através

da média amostral  $y \sim h$ , média amostral de  $\frac{g(y)}{h(y)}$

- Monte Carlo aplicado a outro valor esperado
- Usar  $h$  para reduzir variância!

# Importance Sampling

- Seja  $Y_i$  uma sequência iid de v.a. com distribuição  $h(i)$

$$M_n = \frac{1}{n} \sum_{i=1}^n \frac{g(Y_i)}{h(Y_i)}$$

Como podemos escolher  $h(i)$ , podemos usar o método da transformada inversa para gerar  $y_i \sim h(i)$

- Média e variância do novo estimador

$$E_h[M_n] = E_h\left[\frac{1}{n} \sum_{i=1}^n \frac{g(Y_i)}{h(Y_i)}\right] = \frac{1}{n} \sum_{i=1}^n E_h\left[\frac{g(Y_i)}{h(Y_i)}\right] = G_N$$

$$\text{Var}_h[M_n] = \frac{\sigma_{g/h}^2}{n}$$

Variância da v.a.  $g(Y)/h(Y)$

- $M_n$  converge para  $E_h[g(Y) / h(Y)] = G_N$

- Variância do estimador depende da variância de  $g(Y)/h(Y)$

# Variância da Nova v.a.

- Temos  $g(Y)/h(Y)$ , onde  $Y$  possui distribuição  $h$ , com  $h_i > 0$  para todo  $i$

independe de  $h \leftarrow G_N^2$

$$\sigma_{g/h}^2 = \text{Var}_h \left[ \frac{g(Y)}{h(Y)} \right] = E_h \left[ \left( \frac{g(Y)}{h(Y)} \right)^2 \right] - E_h \left[ \frac{g(Y)}{h(Y)} \right]^2$$

$$G_x^2 = \mathbb{E}[x^2] - \mathbb{E}^2[x]$$

- Segundo momento

$$\rightarrow \sigma_{g/h}^2 = \sum_{i=1}^N \frac{g(i)^2}{h(i)} - G_N^2 = G_N$$

$$E_h \left[ \left( \frac{g(Y)}{h(Y)} \right)^2 \right] = \sum_{i=1}^N \left( \frac{g(i)}{h(i)} \right)^2 h(i) = \sum_{i=1}^N \frac{g(i)^2}{h(i)}$$

- $E_h[g(Y)/h(Y)]$  não depende de  $h$ , mas segundo momento depende

O objetivo é encontrar um  $h$  que coloque massas onde  $g(i)$  é grande

- variância de  $M_n$  depende apenas do segundo momento

# Exemplo

→ assumption:

- Dado  $N$ , calcular  $G_N = \sum_{i=1}^N g(i)$  onde  $g(i) = i \log i$
- Seja  $Y_i$  seq iid de v.a. com distribuição  $h(i) > 0$  para todo  $i$
- **Opção 1:**  $h(i) = 1/N$  para todo  $i$ , ou seja,  $h(i)$  é uniforme( $1, N$ )
  - o que temos feito até agora
- Segundo momento?

$$\sum_{i=1}^N \frac{g(i)^2}{h(i)} = N \sum_{i=1}^N g(i)^2 = N \sum_{i=1}^N i^2 \log^2 i$$

- Como reduzir segundo momento?
- **Ideia:** escolher  $h(i)$  proporcionalmente a  $g(i)$ 
  - maiores valores tem maior probabilidade (com cuidado)

# Exemplo

→ constante

- Opção 2:  $h(i) = i / K_2$ , ou seja linearmente proporcional a  $i$

- onde  $K_2 = 1+2+\dots+N = N(N+1)/2 \rightarrow K_2$  deve ser tal que  $\sum h(i) = 1$

- Segundo momento?  $i^2 \log i$

$$\sum_{i=1}^N \frac{g(i)^2}{h(i)} = K_2 \sum_{i=1}^N \frac{g(i)^2}{i} = K_2 \sum_{i=1}^N i \log^2 i$$

→ dava mais importância a valores mais altos

- Opção 3:  $h(i) = i^3 / K_3$ , ou seja cúbica em  $i$

- onde  $K_3 = 1^3+2^3+\dots+N^3 = N^2(1+N)^2/4 \rightarrow$  A constante agora é proporcional a  $N^4$  !!

$$\sum_{i=1}^N \frac{g(i)^2}{h(i)} = K_3 \sum_{i=1}^N \frac{g(i)^2}{i^3} = K_3 \sum_{i=1}^N \frac{\log^2 i}{i}$$

→ Escondemos a sugestão aqui

# Exemplo

- Qual é a melhor opção?
- A que tiver menor variância (ou menor segundo momento)
- Com N=1000, vamos calcular!

## Opção 1

$$E_h \left[ \left( \frac{g(Y)}{h(Y)} \right)^2 \right] = 1.44 \times 10^{13}$$

## Opção 2

$$E_h \left[ \left( \frac{g(Y)}{h(Y)} \right)^2 \right] = 1.03 \times 10^{13}$$

## Opção 3

$$E_h \left[ \left( \frac{g(Y)}{h(Y)} \right)^2 \right] = 2.75 \times 10^{13}$$

- Melhor estimador é a **opção 2** (menor variância)
  - significa menos amostras para um mesmo erro
  - ou menos erro para um mesmo número de amostras
- Qual seria a melhor  $h(i)$  possível?

Queremos encontrar  $h_i(i)$  que induza a menor variância possível

# O Melhor $h(i)$ Possível

- $h(i)$  que induz variância zero é o melhor possível!

$$\sigma_{g/h}^2 = E_h \left[ \left( \frac{g(Y)}{h(Y)} - \mu_{g/h} \right)^2 \right] = \sum_{i=1}^N \left( \frac{g(i)}{h(i)} - \mu_{g/h} \right)^2 h(i)$$

$\rightarrow$   $E[g(Y)/h(Y)] = G_N$

*Definição do valor esperado* *Força que seja ZERO*  
*↳ constante, que não conhecemos!*

- Se  $\frac{g(i)}{h(i)} = \mu_{g/h}$  para todo  $i$ , então variância é zero!
- A princípio, podemos escolher qualquer  $h(i)$ . Qual o problema então?
- Precisamos saber  $\mu_{g/h}$  que é justamente o que queremos estimar! (*ESTIMAR USANDO O QUE SABEMOS ESTIMAR*)  
→ *uma delas é fazer  $h(i)$  proporcional a  $g(i)$*
- **Ideia:** tentar aproximar esta relação com heurísticas

Lembra que o valor esperado é também um somatório

# Generalização

- Supor que queremos calcular um determinado valor esperado, onde  $X$  tem distribuição dada por  $f$

$$\mu_f = E_f[g(X)] = \sum_i g(i)f(i)$$

- Podemos aplicar *Importance Sampling* neste problema
  - amostrar mais regiões mais importantes para  $g$
- Seja  $h$  outra distribuição para v.a.  $X$ , tal que  $f(i) > 0 \rightarrow h(i) > 0$ 

$\rightarrow$  um somatório de uma  $f_g$  vezes uma probabilidade é um valor esperado em cima

$$\mu_f = \sum_i \frac{g(i)f(i)}{h(i)} h(i) = E_h \left[ \frac{g(X)f(X)}{h(X)} \right]$$
- Temos um outro valor esperado  $E_h$  que pode ser estimado
  - $X$  em  $E_h$  tem distribuição  $h$

$\hookrightarrow$  Aosse a  $h$  cara com o produto  $g \cdot f$ )

1) Gero amostras  $X \sim h(x)$   
 2) Aplico  $\frac{g(x)f(x)}{h(x)}$
- Podemos reduzir variância escolhendo  $h$ 


$\hookrightarrow$  Carando  $h(x)$  com  $g(x) \cdot f(x)$

# Generalização 2

- Tudo vale para o caso de v.a. contínua
  - trocar distribuição por densidade, somatório por integral
- Muitas aplicações no caso contínuo
  - *Monte Carlo Ray Tracing* não funciona sem *Importance Sampling*
  - Espaço de integração é muito grande para uniforme dar bons resultados
  - Muitas heurísticas são usadas nesta aplicação
- **Outro uso:** estimar eventos de baixa probabilidade
  - $E[ I(\text{evento A}) ] = p_A$ , onde A é evento de interesse
  - Mesma ideia, reduzir variância do estimador, aumentar amostragem do evento de interesse

## Importance Sampling

Técnica para gerar amostras de uma distribuição qualquer



$c \cdot p(x) \rightarrow \text{envelope para } q(x)$ :

$$q(x) \leq c \cdot p(x), \quad c \geq 1$$

- 1 Gerar uma amostra  $i$  de  $p_x \rightarrow i \sim p_x$
- 2 Gerar uma amostra uniforme em  $[0, c \cdot p(i)]$   
 $u \sim U[0, c \cdot p(i)]$
- 3 Se  $\begin{cases} u \leq q(i), \text{ retorna } i \\ u > q(i), \text{ repete o processo} \end{cases}$

Uma rodada é aceita com prob.  $p = \frac{1}{c}$ . Assim, na média, precisamos de  $\frac{1}{p} = c$  rodadas para gerar uma amostra.

## Importance Sampling

Técnica para gerar amostras de uma distribuição reduzindo-se a variância do estimador

Queremos gerar amostras de  $g(x)$  mas podemos utilizar amostras de uma distribuição conhecida  $h(x)$  tal que  $h(n) \geq 0$  se  $g(x) \geq 0$

Truque: modificar o valor esperado:

$$\mathbb{E}[g(x)] = \mathbb{E}\left[\frac{g(x)}{h(x)} \cdot h(x)\right] = \mathbb{E}_h\left[\frac{g(x)}{h(x)}\right]$$

$$\text{Se } y_i \sim h(n) \rightarrow \mathbb{E}[g(x)] = \mathbb{E}_h\left[\frac{g(n)}{h(n)}\right] \sim \frac{1}{n} \sum_{i=0}^n \frac{g(y_i)}{h(y_i)}$$