

Aula 12

Aula passada

- Cadeias de Markov
- Definição e exemplos
- Modelo On-Off
- Sem memória
- Distribuição no tempo
- Irredutibilidade
- Aperiodicidade

Aula de hoje

- Distribuição estacionária
- Tempo de chegada
- Distância de variação total
- Convergência
- Reversibilidade
- Passeios aleatórios

Cadeia de Markov

- Seja S o espaço de estados da CM, e P a matriz de transição de estados
- Seja X_t uma v.a. que determina o valor do estado da cadeia no instante de tempo t , para $t = 0, 1, 2, \dots$
- Estamos interessados em
 - $P[X_t = s] = \pi_s(t)$
- Sabemos que para um estado inicial, temos
$$\pi(t) = \pi(t-1)P = \pi(0)P^t$$

Mas para onde vai $\pi(t)$?

- será que depende em $\pi(0)$?

Possível Convergência

- Observação 1: X_t não converge
 - X_t passeia pela cadeia para sempre, trocando de estado
- Observação 2: $P[X_t = s_i]$ pode convergir
 - Prob. de encontrar X_t no estado s_i , ou fração de vezes que X_t visita o estado s_i (intuitivamente)
- Estamos interessados em valores grandes de t
$$\lim_{t \rightarrow \infty} \pi(t) = \lim_{t \rightarrow \infty} \pi(0) P^t$$
 - mas temos que formalizar este limite

Distribuição Estacionária


- Seja π um vetor de distribuição em uma CM com matriz de transição P
- Dizemos que π (vetor linha) é uma distribuição estacionária sse

$$\pi_s \geq 0 \quad \sum_{s \in S} \pi_s = 1 \quad \longleftarrow \text{Vetor de probabilidade}$$

$\pi P = \pi \longrightarrow \pi_i = \sum_j \pi_j P_{ji}$, para todo i

- Ou seja, ao multiplicar π por P temos π de volta
 - “estacionou”, não temos mais dinâmica!
- Repare que se $\pi(0)$ é uma distribuição estacionária, então $\pi(1) = \pi(0)P = \pi(0)$

Exemplo Modelo On-Off



$$P = \begin{pmatrix} .75 & .25 \\ .67 & .33 \end{pmatrix}$$

$$\pi = (8/11 \quad 3/11) \quad \longleftarrow \text{Distribuição estacionária}$$

- Verificando: $\pi P = ?$

$$\pi_1 = 8/11 * 3/4 + 3/11 * 2/3 = 8/11$$

$$\pi_2 = 8/11 * 1/4 + 3/11 * 1/3 = 3/11$$

- Se $\pi(0) = \pi$ então temos que $\pi(1) = \pi(0)P = \pi$
 - vetor de probabilidade está estacionado!

Tempo de Chegada

- T_{ij} : Tempo necessário para sair de um estado s_i e chegar a outro estado s_j (*hitting time*)
 - número de transições, T_{ij} é aleatório, $\tau_{ij} = E[T_{ij}]$
$$T_{ij} = \min \{ t \mid X_t = s_j \wedge X_0 = s_i \}$$
- Se $i = j$, temos τ_{ii} , chamado de tempo médio de retorno ao estado s_i
 - número médio de transições para sair e voltar ao estado s_i
- T_{ij} não depende de $\pi(t)$ pois estamos condicionando em estar em s_i

Todos os estados
aperiódicos

Tempo de Chegada

→ grafo fortemente conexo

- Teorema: Para qualquer CM irreduzível e aperiódica, para quaisquer dois estados s_i e s_j , temos o seguinte:

$$P[T_{ij} < \infty] = 1$$

$$P[T_{ij} = \infty] = 0$$

$$E[T_{ij}] = \tau_{ij} < \infty$$

- Probabilidade de T_{ij} ser infinito é zero

- Não há chances de sair de s_i ficar circulando pela cadeia e nunca chegar a s_j

Em algum momento vou chegar em todos os estados

- Valor esperado do tempo de retorno para qualquer estado s_i é finito
- Boa notícia!

Distribuição Estacionária e Tempo de Retorno


- Teorema: Para qualquer CM irreduzível e aperiódica, para qualquer estado s_i , temos a seguinte relação

$$\pi_i = \frac{1}{\tau_{ii}}$$

- Relação entre tempo médio de retorno e distribuição estacionária
- Conhecer um determina o outro!
- **Intuição:** na média o processo visita s_i 1 vez a cada τ_{ii} passos

$\tau_{ii} = 1 / \pi_i$
↳ probabilidade
Parece o valor esperado
de uma geométrica

Exemplo



$$P = \begin{pmatrix} .75 & .25 \\ .67 & .33 \end{pmatrix}$$

$$\pi = (8/11 \quad 3/11)$$

- Tempo médio de retorno do estado On (1) e Off (2) ?
- $\tau_{11} = 1/\pi_1 = 11/8 = 1.375$
- $\tau_{22} = 1/\pi_2 = 11/3 = 3.666$

Variação Total

- Como medir a distância entre dois vetores?
 - Precisamos disto para medir aproximação da distribuição estacionária
 - há muitas maneiras, uma delas é variação total
- Seja α e β dois vetores de probabilidade em S , a distância de variação total entre eles é dada por

$$d_{TV}(\alpha, \beta) = \frac{1}{2} \sum_k |\alpha_k - \beta_k|$$

$\leftarrow d_{TV}$ tem valor entre 0 e 1

\hookrightarrow normalização

- Sequência de vetores α_t converge para β em variação total sse

$$\lim_{t \rightarrow \infty} d_{TV}(\alpha_t, \beta) = 0$$

A maior diferença acontece quando colocamos toda a massa de prob. de α em α_i e a de β em β_j

Figueiredo 2018

$$\alpha = [0 \ 1] \quad \beta = [1 \ 0] \quad \rightarrow \quad \sum |\alpha_k - \beta_k| = |1 - 0| + |0 - 1| = 2$$

Convergência de CM

Teorema Fundamental das Cadeias de Markov

- Teorema: Para qualquer CM irreduzível e aperiódica, para qualquer condição inicial $\pi(0)$, temos que $\lim_{t \rightarrow \infty} d_{TV}(\pi(t), \pi) = 0$
 \nearrow sequência de vetores no tempo $\leftarrow \pi$ é uma distribuição estacionária da CM

- Além disso, π é única! Corolário

- CM sempre converge para a mesma distribuição estacionária, independente da condição inicial
- Também chamado de estado estacionário, ou equilíbrio da CM

Encontrando π

- Ótima notícia, mas como encontrar π ?

1) Método iterativo

$$\pi(t) = \pi(t-1)P = \pi(0)P^t$$

- fazer iteração até critério de convergência

2) Método direto

$$\pi = \pi P$$

- resolver sistema de equações, adicionando a equação


$$\sum_i \pi_i = 1$$

3) Monte Carlo

- Usar própria cadeia para gerar amostras para estimar π_i ou estimar τ_{ij} para todo s_i

Modelo On-Off

- Distribuição estacionária?
- Sistemas de equações



$$\pi_i = \sum_j \pi_j P_{ji} \quad \sum_i \pi_i = 1$$

$$\pi_1 = \pi_1 P_{11} + \pi_2 P_{21} = (1-p)\pi_1 + q\pi_2$$

$$\pi_2 = \pi_1 P_{12} + \pi_2 P_{22} = p\pi_1 + (1-q)\pi_2$$

$$\pi_1 + \pi_2 = 1$$

- Substituindo $\pi_2 = 1 - \pi_1$ na primeira equação, temos

$$\pi_1 = (1-p)\pi_1 + q(1-\pi_1) \rightarrow \pi_1 = \frac{q}{p+q}$$

$$e \quad \pi_2 = \frac{p}{p+q}$$

Reversibilidade

- Uma classe bem especial de CM
 - usada por muitos algoritmos, incluindo MCMC
- Reversível no tempo: evolução de X_t é o mesmo se t vai para frente ou para trás
- Uma CM é dita reversível para a distribuição de probabilidade π sse


$$\pi_i P_{ij} = \pi_j P_{ji}$$

Massa de prob fluindo de s_i para s_j = Massa de prob fluindo de s_j para s_i

- Se π existe então π é também distribuição estacionária
- Uma forma ainda mais forte de equilíbrio!

Passeios Aleatórios

- Seja $G=(V, E)$ um grafo não direcionado
- Considere um andarilho que passeia pelo grafo de forma aleatória, sem preferência e sem memória
 - escolhe uniformemente próximo vértice entre vizinhos do vértice atual



- $p_{12} = 1/2, p_{13} = 1/2, p_{21} = 1/3, p_{23} = 1/3, p_{24} = 1/3, \dots$

Passeios Aleatórios

- Nosso andarilho induz uma cadeia de Markov sobre o grafo G
 - forma de colocar o grafo em “movimento”
- X_t : vértice onde andarilho se encontra no tempo t
- Matriz de transição de probabilidade
 - $P = D^{-1} A$
 - D^{-1} é a matriz diagonal com o inverso do grau de cada vértice
 - A é a matriz de adjacência de G
- Outra forma: $P_{ij} = 1/d_i$ se (i, j) são vizinhos, 0 c.c.
 - onde d_i é o grau do vértice i

Passeios Aleatórios

- Qual a distribuição estacionária do andarilho ?

$$\pi_i = \frac{d_i}{K} \quad K = \sum_i d_i = 2m \quad \leftarrow m \text{ é o número de arestas em } G$$

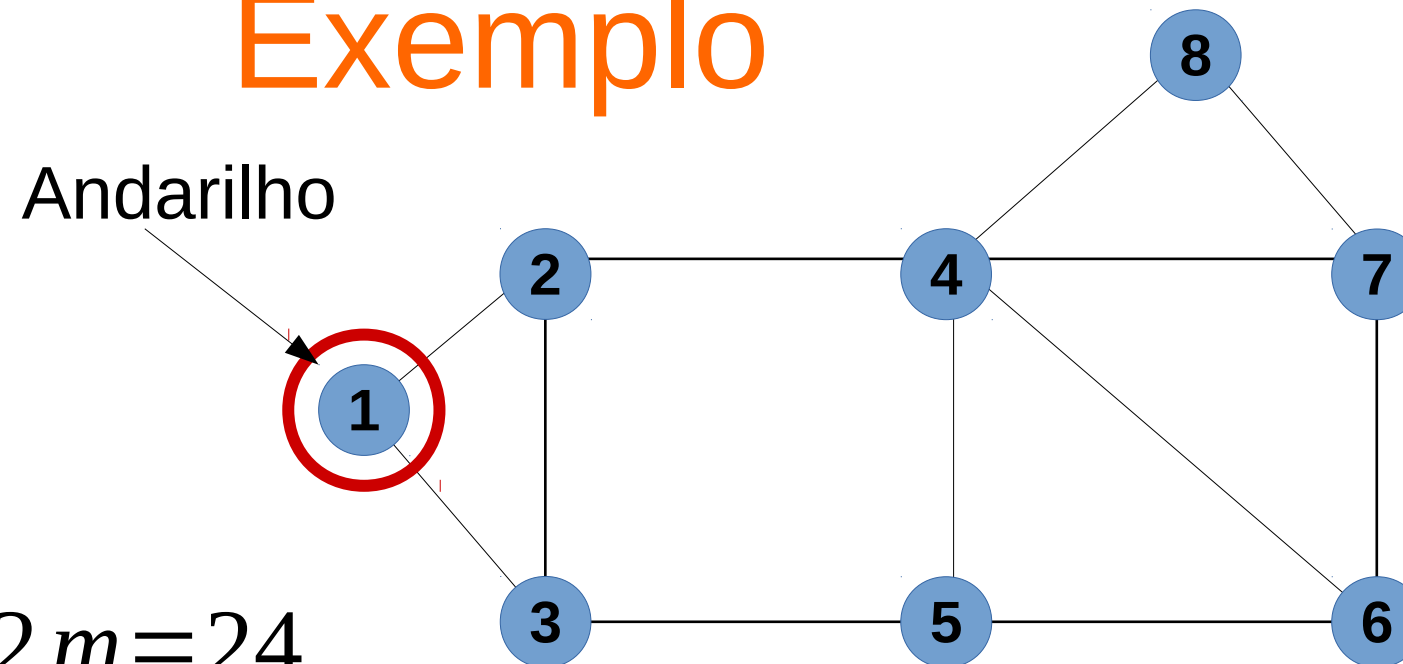
- **Incrível:** só depende do grau do vértice i
 - K é constante de normalização
 - Todos os vértices com mesmo grau em igual prob
- Além disso, esta CM é reversível

$$\pi_i P_{ij} = \pi_j P_{ji} \quad \leftarrow \text{Podemos verificar}$$

- tanto faz andarilho andar para frente ou para trás
- equilíbrio mais forte para esta CM

Exemplo

Andarilho




$$K = \sum_i d_i = 2m = 24$$

$$\pi = \left(\frac{2}{24} \quad \frac{3}{24} \quad \frac{3}{24} \quad \frac{5}{24} \quad \frac{3}{24} \quad \frac{3}{24} \quad \frac{3}{24} \quad \frac{2}{24} \right)$$

- Independente de onde andarilho inicia, distribuição de sua posição converge para π
 - prob de encontrar o andarilho no vértice i

Outro Exemplo



- CM é irredutível? **Sim!**
 - CM é aperiódica? **Sim!** *→ self-loops*
 - Qual é sua distribuição estacionária?
 - por inspeção, sem fazer conta
- $\pi_i = \frac{1}{4}$ para $i = 1, 2, 3, 4$
- Podemos verificar facilmente!

- CM é reversível? **Não!**

$$\pi_1 p_{12} = \frac{1}{4} \frac{6}{10} = \frac{3}{20} \neq \pi_2 p_{21} = \frac{1}{4} \frac{3}{10} = \frac{3}{40}$$

- **Intuição:** processo gira mais em uma direção (anti-horário)
 - direção do tempo (para frente ou para trás) determina direção mais girada, não sendo reversível

DISTRIBUIÇÃO ESTACIONÁRIA : π é uma distribuição estacionária da MC se :

$$\pi P = \pi \quad \text{ou} \quad \pi_i = \sum_j \pi_j \cdot P_{ji}$$

Tempo de Chegada : T_{ij} é uma variável aleatória que indica o tempo mínimo para ir de $i \rightarrow j$.

$$T_{ij} = E[T_{ij}]$$

Se a MC for irredutível e aperiódica:

$$P[T_{ij} < \infty] = 1 \quad (T_{ij} < \infty)$$

$$\pi_i = 1 / T_{ii}$$

Reversibilidade : Não consigo diferenciar se $i \rightarrow j$ ou se $j \rightarrow i$

$$\pi_j \cdot P_{ji} = \pi_i \cdot P_{ij}$$

Convergência: Se a MC é irredutível e aperiódica, então a convergência para π é única e independente de $\pi(0)$