

Aula 15

Aula passada

- Autovalores, autovetores, decomposição
- Convergência para estacionaridade
- Tempo de mistura
- Spectral gap
- Tempo de mistura de passeios aleatórios

Aula de hoje

- Caminho amostral
- Teorema Ergódico
- Estimando π
- Simulação de CM
- Gerando amostras
- Markov Chain Monte Carlo (caso simétrico)
- Exemplo

Aleatoriedade de CM

- Até agora vimos os seguintes objetos matemáticos
- P : matriz de transição de estados da CM
- $\pi(0)$: distribuição inicial da CM
- $\pi(t)$: distribuição da CM no tempo t , dada por $\pi(t) = \pi(0)P^t$
- π : distribuição estacionária da CM, dada por $\pi = \pi P$
- τ_ε : tempo de mistura da CM, dado ε
↳ tempo mínimo para que $d_{TV}(\pi(t), \pi) \leq \varepsilon$

Qual destes objetos é aleatório?

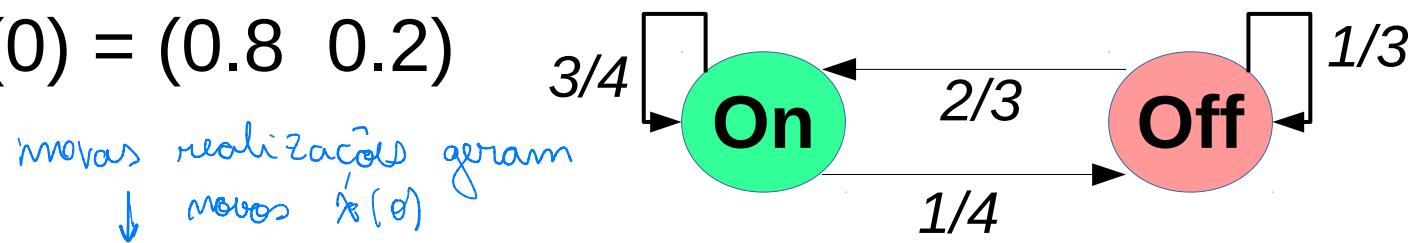
- **Nenhum deles!**
- Então o que é aleatório na CM?

Cadeia de Markov

- Seja P a matriz de transição de estados de uma CM
- Seja X_t uma v.a. que determina o estado da cadeia no instante de tempo t , para $t = 0, 1, 2, \dots$
 - $P[X_t = s]$ para todo s em S

X_t é aleatório (é uma v.a.)

- Exemplo: $\pi(0) = (0.8 \ 0.2)$
novas realizações geram novos $\pi(t)$
- Realização: $X_0 = 1, X_1 = 0, X_2 = 0, X_3 = 1, X_4 = 0, X_5 = 1, X_6 = 1, \dots$
- Realização: $X_0 = 0, X_1 = 0, X_2 = 1, X_3 = 1, X_4 = 0, X_5 = 0, X_6 = 1, \dots$
- Realização: $X_0 = 1, X_1 = 1, X_2 = 0, X_3 = 1, X_4 = 1, X_5 = 1, X_6 = 0, \dots$



Caminho Amostral

- Uma realização da sequência de v.a. X_t para $t = 0, 1, \dots$
- Probabilidade de um caminho amostral $\omega = (\omega_0, \omega_1, \omega_2, \dots)$
 - prob. da CM realizar exatamente ω

$$P[\omega] = P[X_0 = \omega_0, X_1 = \omega_1, \dots] = \\ = \pi_{\omega_0}(0) P_{\omega_0, \omega_1} \overset{\text{realizado}}{\sim} P_{\omega_1, \omega_2} \overset{\text{realizado}}{\sim} P_{\omega_2, \omega_3} \dots$$

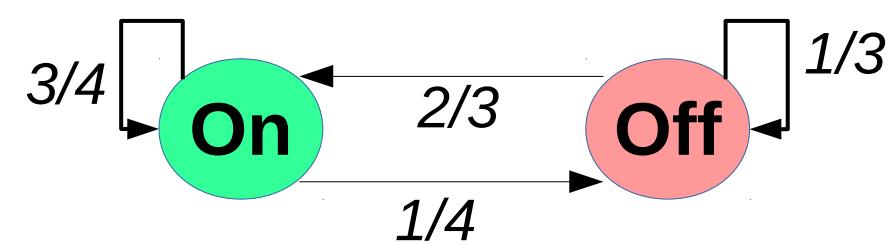
$\omega_t \rightarrow o$ que aconteceu!
Logo, ω é aleatório

mas é aleatório

Adicionou valores < 1
no cálculo de $P[\omega]$

- Todo caminho amostral ω tem uma probabilidade $P[\omega] \rightarrow 0$
 - que vai a zero com o comprimento do caminho!
- Exemplo: $\pi(0) = (0.8 \ 0.2)$

- $\omega = 1, 1, 1, 1, 1, 1, 1, 1, 1$ $0.8 \times \left(\frac{3}{4}\right)^7$
- $\omega = 0, 1, 0, 1, 0, 1, 0, 1$ $0.2 \times \left(\frac{2}{3} \times \frac{1}{4} \times \frac{2}{3} \times \frac{1}{4} \times \frac{2}{3} \times \frac{1}{4} \times \frac{2}{3}\right)$



$$P[\omega] = ?$$

O que ocorre com X_t ?

- Se todo caminho amostral tem probabilidade que vai a zero, o que podemos dizer sobre sequência X_t ?

Usar a média sobre valores da sequência!

→ Não queremos olhar para 1 caminho, mas para uma média de caminhos

- Ex. média amostral dos valores de estado observados

$$S_k = \frac{1}{k} \sum_{t=0}^{k-1} X_t$$

- Ex. fração de vezes que um estado s é visitado

$$f_k(s) = \frac{1}{k} \sum_{t=0}^{k-1} I(X_t = s)$$

Se diz quantas vezes esteve no estado s na realização

Convergência Intuitiva

- Para onde converge a média amostral de X_t , com um grande número de amostras (k muito grande)?
 - caminho amostral muito longo pela CM

$$S_k = \frac{1}{k} \sum_{t=0}^{k-1} X_t \xrightarrow{\text{converge para}} E_{\pi}[X] = \sum_s s \pi_s$$

Lembre que não é o estado que converge, mas a probabilidade de se estar naquele estado

- Para onde converge a fração de visitas a um estado, com um grande número de amostras (k muito grande)?

$$f_k(s) = \frac{1}{k} \sum_{t=0}^{k-1} I(X_t = s) \xrightarrow{\text{converge para}} \pi_s$$

$f: \mathbb{X} \rightarrow \mathbb{R}$

Teorema Ergódico

- Seja f uma função sobre o espaço de estados da CM
 - mapeia cada estado da CM em um valor real
- Se CM é irredutível e aperiódica, com distribuição estacionária π , temos

$$P\left[\lim_{k \rightarrow \infty} \frac{1}{k} \sum_{t=0}^{k-1} f(X_t) = E_{\pi}[f(X)]\right] = 1$$

(máximo amostral)

tempo

espaco

Sobre distribuição estacionária

convergência forte; quando
tendo um limite dentro
de probabilidade

Como lei forte dos
grandes números!

- Teorema fundamental: Média no espaço = média no tempo
 - valor esperado de qualquer função pode ser aproximado usando caminho amostral
- Exemplos anteriores são casos especiais

Estimando π

- Teorema ergódico garante que método de Monte Carlo funciona também em CM
 - conexão entre teoria (equações) e prática (simulação)
- Exemplo: Como estimar π ?
- Usar a CM para gerar um caminho amostral ω bem longo e calcular a fração de visitas a cada estado

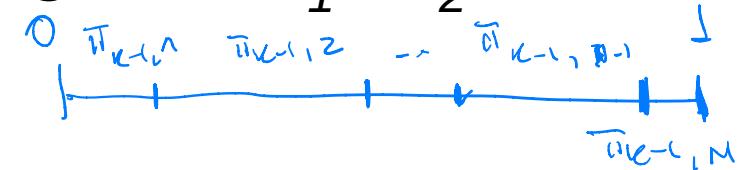
Nos diz que, para estimar π_s ,
basta que contemos
a fração de
vezes que visitarmos
o estado s

$$\hat{\pi}_s(k) = \frac{1}{k} \sum_{t=0}^{k-1} I(\omega_t = s)$$

- Teorema ergódico garante convergência
 - estimador consistente (possui viés para tempo k)
- Outro método para encontrar π

Simulando uma CM

- Como simular uma CM? → Quero gerar o caminho amostral ω muito longo
 - entrada: matriz P , distribuição inicial $\pi(0)$
- Simular cada valor X_t , para $t=0,1,\dots$
- Usar $\pi(0)$ para gerar X_0
- Usar P (matriz de transição) para gerar X_1, X_2, \dots
- Como gerar X_k dado X_{k-1} ?



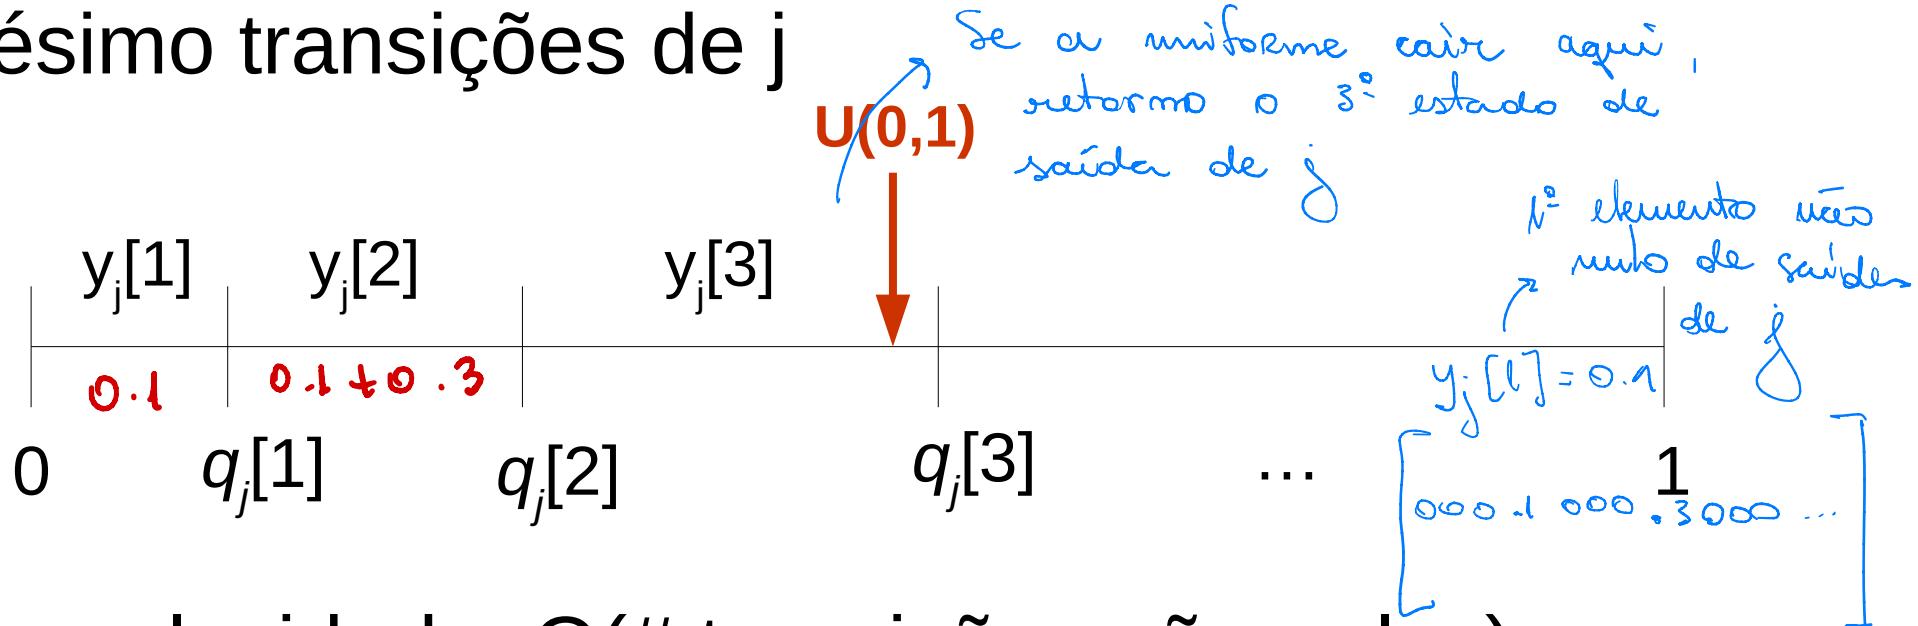
Método da transformada inversa!

- Gerar $U \sim \text{uniforme}(0,1)$, usar (X_{k-1}) -ésima linha da matriz P para escolher vizinho, valor de X_k
- Problema: ineficiente (se matriz P é esparsa)

Simulando CM Eficientemente

i : i -ésima transição

- Representar matriz P como vetor de adjacência
 - apenas entradas não-nulas são representadas
- $y_j[i] =$ estado da i -ésima transição não-nula do de j
- $q_j[i] =$ prob. de transição acumulada das primeiras i -ésimo transições de j



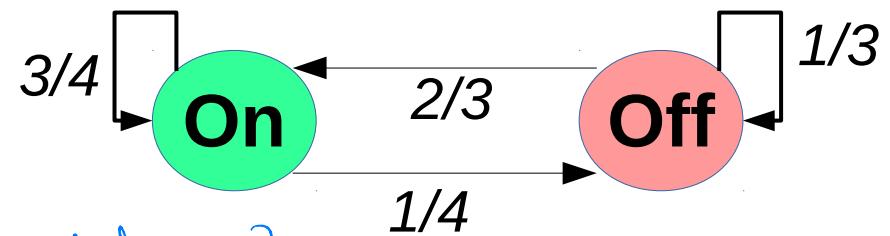
- Complexidade: $O(\# \text{ transições não-nulas})$
- **Método Alias:** complexidade $O(1) + \text{custo inicial}$

↳ agora amostras em um tempo constante

Gerando Amostras

- Considere uma CM com matriz de transição P
- Como gerar amostras de X_t ?
- Exemplo: $\pi(0) = (0.8 \ 0.2)$
- Gerar amostras de X_{10} ?
(Calcular $\pi(10)$) e gerar uma amostra deste vetor
- Ideias

- 1) Calcular $\pi(t)$, gerar amostras desta distribuição
- 2) Simular CM até X_t , para cada amostra



Qual é a melhor abordagem?

- Depende de n (tamanho da CM), e t (*quantidade de amostras*)
muitas amostras → método 1, poucas amostras → método 2

Espaços Grandes e Complicados

- Considere um espaço amostral grande e complicado
 - grande = muitos elementos (10^{50} estados)
 - complicado = não é fácil enumerar os elementos
- Todos os grafos conexos com n vértices → *cada grafo é um estado*
 - não é fácil enumerar grafos conexos
- Todos os percursos por n cidades de comprimento L ou menor
 - não é fácil enumerar percursos de comp. L ou menor
- Em geral: espaço amostral combinatorial com restrições que dificultam enumeração *Como gerar amostras do espaço amostral?*

Como gerar amostras destes espaços?

Gerando amostras uniformes

- Como gerar amostras uniformes destes espaços?

Ideia preliminar ↗ Quero que cada estado tenha a mesma prob.
de ser amostrado

- 1) Aumentar espaço de estado amostral (ex. removendo restrição) – facilitar geração
- 2) Usar método da rejeição – rejeitar amostras que não atendem a restrição, remover viés
- Exemplo: Gerar grafos conexos com n vértices?
 - modelo $G(n, p)$ com $p=1/2$ todos os grafos são equiprováveis (não temos viés)
 - gerar grafo de $G' \sim G(n, 1/2)$
 - retorna se G' é conexo, caso não gera outro G'

Problema?

- Pode ser muito ineficiente! *Possa exigir muitos grafos*

Markov Chain to the Rescue

- Como usar CM para resolver este problema?
- Construir CM cujos estados correspondem aos elementos de S (espaço amostral)
- Construir uma matriz de transição P tal que distribuição estacionária π seja uniforme
- Simular CM para gerar amostras
 - dar τ_ϵ passos para gerar uma amostra

* Uma
árvore de n
nótes
possui $n-1$
arestas

Markov Chain Monte Carlo (MCMC)

• O que é?

- Método baseado em CM para gerar amostras de uma distribuição qualquer
 - não precisa ser uniforme

Posso escolher qualquer T_i ,
desde que P esteja de acordo
com o π desejado

Técnica para gerar amostras de um espaço de estados com uma distribuição qualquer.

MCMC

Simulamos um caminho amostral!
} que é?
} como funciona?
Porque funciona?

Como construir CM, se S é muito grande?

- Não precisamos construir a priori Simulamos um estado de cada vez, sem saber todos os estados
- Podemos construir e simular CM ao mesmo tempo, um passo de cada vez

Qual CM mais apropriada?

- Baixo tempo de mistura τ_ϵ , para gerar amostras mais rapidamente
↳ Para ter simulações mais certas e convergir mais rápido -
- Poucas transições de saída em cada estado (ex. log n)
- Fácil descrição dos estados vizinhos (a partir do estado atual)
- Tema de grande debate e avanço!

MCMC – Caso Simétrico

- Considere uma CM com matriz de transição P simétrica
 - $P_{ij} = P_{ji}$ para todo estado i, j $\pi_i \cdot P_{ij} = \pi_j \cdot P_{ji}, \forall i, j$
- Distribuição estacionária é uniforme e a CM é reversível
- Queremos modificar P para construir uma nova CM cuja distribuição estacionária seja π qualquer
 - π é entrada para o problema
aceitar / rejeitar a transição de estados
- Ideia: não “aceitar” todas as transições da CM original
 - continuar no mesmo estado para induzir π qualquer
 - parecido com método da rejeição não uniforme
- Rejeição é probabilística, para cada transição não-nula em P , temos $a(i, j) \rightarrow$ probabilidade de aceitar a transição a_{ij}

Ideia: transformar uma cadeia de π uniforme para uma de π qualquer ficando mais tempo em um estado

MCMC – Caso Simétrico

- Considere CM no estado i e uma proposta de transição da CM original (ou seja, em P) para o estado j
 - aceita transição com probabilidade $a(i, j)$, rejeita com complemento

- Matriz de transição P' da nova CM

$$P'_{ij} = \begin{cases} P_{ij} a(i, j), & \text{se } i \neq j \\ 1 - \sum_{k:k \neq i} P_{ik} a(i, k), & \text{se } i = j \end{cases}$$

Prob. de transicionar, vezes prob. de aceitar

transições do vértice para ele mesmo

Self-loop → rejeição das transições

- Temos que escolher $a(i, j)$ tq P' tenha distribuição estacionária dada por π , ou seja:

$$\pi_i P_{ij} a(i, j) = \pi_j P_{ji} a(j, i)$$

O estado estacionário deve ser de P'

Garantindo também que P' é reversível

MCMC – Caso Simétrico

- Como $P_{ij} = P_{ji}$ (por simetria em P), temos

$$\pi_i a(i, j) = \pi_j a(j, i)$$

- Como $a(i, j)$ e $a(j, i)$ são probabilidades, temos

$$\pi_i a(i, j) \leq \pi_i \quad \pi_i a(i, j) = \pi_j a(j, i) \leq \pi_j$$

- Como $a(i, j)$ deve ser o maior possível para evitar desperdício, temos (quanto menor a $a(i, j)$ · mais rejeições)

$$a(i, j) = 1, \quad \text{se } \pi_i \leq \pi_j$$

$$a(i, j) = \frac{\pi_j}{\pi_i}, \quad \text{se } \pi_i > \pi_j$$

- Ou seja,

$$a(i, j) = \min \left\{ 1, \frac{\pi_j}{\pi_i} \right\}$$

Prob. do estado
 $(x, y) \rightarrow \pi$

Exemplo

- Gerar amostras de pares ordenados (x, y) em $[1, n] \times [1, n]$
 - grid 2D discreto e quadrado com n pontos

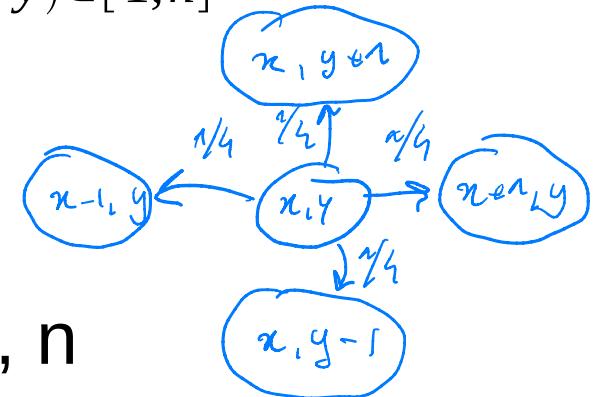
$\xrightarrow{\text{Entrada do problema}}$

$$P[(x, y)] = \frac{(x+y)^2}{Z}$$

pode. de agrar o ponto
 (x, y)

constante de
normalização

$$Z = \sum_{(x, y) \in [1, n]^2} (x+y)^2$$



- CM original é torus 2D com $n \times n$ vértices
 - estado dado por (x, y) , com $x, y = 1, \dots, n$
 - todo estado tem 4 transições, $P_{ij} = 1/4$, para algum i, j
 - CM é simétrica e consequentemente uniforme
- Como transformar P em P' para induzir π conforme definição acima?

Como distorcer $P_{ij} = 1/4$ para termos a distribuição π ?



Para a borda, vamos para a outra borda.

Exemplo

- Precisamos CM tal que $\pi_{(x,y)} = \frac{(x+y)^2}{Z}$
- Seja estado $i = (x,y)$ e $j = (x',y')$. Desta forma, podemos definir $a(i, j)$ como
$$a(i, j) = \min \left\{ 1, \frac{\pi_j}{\pi_i} \right\} = \min \left\{ 1, \frac{(x'+y')^2}{(x+y)^2} \right\}$$

↳ probabilidade de aceitar a transição

↳ distribuição que queremos induzir

não precisa calcular a constante de normalização
- Por fim, definimos P' como anteriormente
 - $P'_{ij} = P_{ij}^{1/4} a(i,j)$ se $i \neq j$, etc. A nova MC é definida por P'_{ij}
↳ se $i=j$ preciso calcular a prob. complementar
- **Boa notícia:** não precisamos calcular Z para definir $a(i, j)$
 - seria proibitivo calcular Z de um vértice para ele mesmo
A mudança só adiciona arestas
- Para gerar uma amostra, simular CM definida por P' por τ_ε e retornar o estado atual