

Aula 16

Aula passada

- Caminho amostral
- Teorema Ergódico
- Estimando π
- Simulação de CM
- Gerando amostras
- Markov Chain Monte Carlo (caso simétrico)
- Exemplo

MH → a prob. depende apenas
dos estados vizinhos

Aula de hoje

- Metropolis-Hastings
- Amostrando vértices
- Modelo Hardcore
- Gibbs Sampling (ou Glauber Dynamics)
- Gerando q-colorações

O que é MHC? - uma técnica
para gerar amostras de uma dist.

Como? - Plantar uma RC e a simular
para amostrar os objetos

Markov Chain Monte Carlo

- **Problema:** gerar amostras de um espaço S grande e complicado com distribuição π
 - ex: amostrar grafos conexos com n vértices com probabilidade proporcional ao número de arestas
- **Solução:** Markov chain Monte Carlo
 - construir uma CM com espaço de estado S tal que π seja sua distribuição estacionária
 - gerar amostras através de caminhos amostrais de comprimento τ_ε
- **Dificuldade:** construir CM que seja eficiente em termos de calcular transições e tempo de mistura
 - arte com dicas de engenharia

Construindo a CM para MCMC

- **Ideia 1:** partindo de uma CM aperiódica e irredutível, transformar cadeia em outra mudando valores de transições não nulas, tq distribuição estacionária seja π
- **Ideia 2:** não “aceitar” todas as transições da CM original, continuar no mesmo estado para induzir π qualquer
 - para cada transição não-nula em P , temos probabilidade de rejeição $a(i, j)$
- **Problema:** encontrar $a(i, j)$ tq nova CM tenha distribuição π

Algoritmo (ou cadeia) de Metropolis-Hastings

- Aula passada: P simétrica, ou seja $P_{ij} = P_{ji}$
- P qualquer no próximo slide → não necessariamente simétrica

Metropolis-Hastings

- Considere CM no estado i e uma proposta de transição da CM original (ou seja, em P) para o estado j
 - aceita transição com probabilidade $a(i, j)$, rejeita com complemento
- Matriz de transição P' da nova CM

$$P'_{ij} = \begin{cases} P_{ij} a(i, j), & \text{se } i \neq j \\ 1 - \sum_{k:k \neq i} P_{ik} a(i, k), & \text{se } i = j \end{cases} \xrightarrow{\text{loop}}$$

- Temos que escolher $a(i, j)$ tal que
$$\pi_i P_{ij} a(i, j) = \pi_j P_{ji} a(j, i)$$
 → ↓ equações, 2 variáveis
 - garante que π é distribuição estacionária de P'
 - garante que P' é reversível

Metropolis-Hastings

- Como $a(i,j)$ e $a(j,i)$ são probabilidades, temos

$$\pi_i P_{ij} a(i,j) \leq \pi_i \quad \pi_i P_{ij} a(i,j) = \pi_j P_{ji} a(j,i) \leq \pi_j$$

- Como $a(i,j)$ deve ser o maior possível para evitar desperdício, temos

$$a(i,j) = 1, \quad \text{se } \pi_i P_{ij} \leq \underbrace{\pi_j P_{ji}}_{\text{Fluxo de } j \rightarrow i}$$

Se o fluxo de $i \rightarrow j$ é menor que $j \rightarrow i$, então sempre aceito a prob. de transição

$$a(i,j) = \frac{\pi_j P_{ji}}{\pi_i P_{ij}}, \quad \text{se } \pi_i P_{ij} > \pi_j P_{ji}$$

- Ou seja,

$$a(i,j) = \min \left\{ 1, \frac{\pi_j P_{ji}}{\pi_i P_{ij}} \right\}$$

$\{a(i,j) \text{ e } a(j,i)\} \rightarrow \text{um deles é 1}$

Caso 1: $a_{ij} = 1 \Rightarrow$

$$\pi_i \cdot P_{ij} = \pi_j \cdot P_{ji} \cdot a_{ji} \rightarrow \text{é o menor}$$

$$a_{ji} = \min \left\{ 1, \frac{\pi_i \cdot P_{ij}}{\pi_j \cdot P_{ji}} \right\}$$

FABER 2018

- Entradas de P' calculadas desta forma

$$= \frac{\pi_i \cdot P_{ij}}{\pi_j \cdot P_{ji}}$$

Amostrando Vértices

- Considere grafo grande e desconhecido (não conhecemos os vértices ou as arestas, a priori)
 - ex. grafo de amizades do facebook
- Podemos percorrer o grafo: a partir de um vértice, descobrir seus vizinhos
- Como gerar amostras de vértices uniformemente?
 - ex. estimar fração de brasileiros no FB
- **Ideia 1:** BFS $\xrightarrow{\text{pegar os vizinhos, depois os vizinhos dos vizinhos, e}} \text{amostrar uniforme no vértices}$ descobertos $\xrightarrow{\text{A amostra é enviesada pelo quantitativo de amigos que um vértice tem}}$ $\xrightarrow{\text{retornos uns vértices aleatórios}}$
- **Ideia 2:** Passeio aleatório de comprimento k , retornar vértice X_k $\xrightarrow{\text{Posso transformar uma MC em outra MC com distribuição uniforme}}$

Como garantir que amostra é uniforme?

- Ideias 1 e 2 geram amostras enviesadas (não uniformes)

MCMC to the Rescue

- Construir CM usando algoritmo de Metropolis-Hastings tq π seja uniforme nos vértices *π^{tar} é a distribuição estacionária da cadeia que queremos gerar.*
 - $\pi_v = 1/Z$ onde Z é o número de vértices da rede (desconhecido)
 \hookrightarrow poderia não ser uniforme
- Modificar CM induzida por um passeio aleatório (que não é simétrica)
- Definindo probabilidade de aceite
 - CM original, temos: $P_{ij} = 1/d_i$, $P_{ji} = 1/d_j$
 \hookrightarrow NÃO precisamos de Z
 - $$a(i,j) = \min\left\{1, \frac{\pi_j P_{ji}}{\pi_i P_{ij}}\right\} = \min\left\{1, \frac{d_i}{d_j}\right\}$$

depende apenas de onde estou partindo

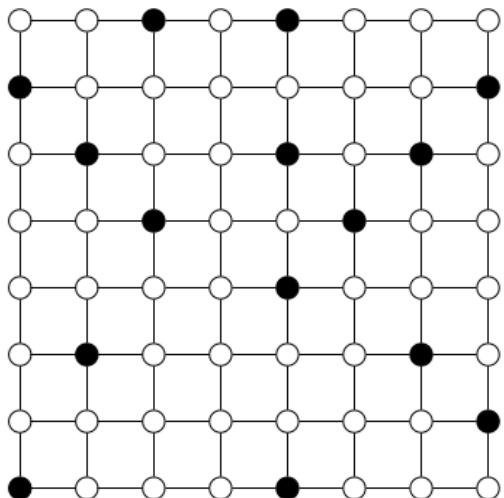
CM desejada

$$\pi_i = \pi_j = \frac{1}{Z}$$

 - Se d_j grande, há uma menor probabilidade de aceite. Logo, remove o viés dos vértices com grau alto no passeio aleatório*
- Logo $P'_{ij} = 1/d_i * \min\{1, d_i / d_j\}$
- Enviesa o passeio contra vértices de grau alto, dando distribuição estacionária uniforme
- Método usado na prática, hoje em dia!

Exemplo – Hardcore Model

- Modelo *hardcore*: atribuir bolinhas aos vértices de um grafo tal que vértices vizinhos não possuam bolinhas
 - vértice pode ter 0 ou 1 bolinha



- Dado um grafo $G=(V, E)$, S é o conjunto de todas as configurações, e S' o subconjunto de configurações válidas
 - $|S| = 2^n$, para grafo com n vértices
- **Problema:** qual é o valor esperado do número de bolinhas de uma configuração?
 - distribuição uniforme sobre o espaço S'

O número máximo de bolinhas ligadas é $n/2$

Em geral, a dificuldade em aplicar Metropolis-Hastings está em definir a CN inicial (seus estados e transições).

Exemplo – Hardcore Model

- Seja $n(C)$ o número de bolinhas de uma configuração C , escolhida ao acaso (uniformemente)

- Então

$$E[n(C)] = \frac{1}{Z} \sum_{c \in S'} n(c) \quad Z = |S'| = \sum_{c \in S} 1 \text{ (} c \text{ é válida)}$$

quantas bolas pretas há na configuração C

prob. de escolher uma config. válida

conjunto de config. válidas

Quantas configurações existem

- **Problemas:**

- (1) como enumerar S' de forma eficiente?
- (2) como lidar com o tamanho de S' (exponencial)?

- **Solução:** Markov Chain Monte Carlo

Construir uma MC onde os estados são configurações válidas.

MC/MC → técnica para gerar amostras com qualquer distribuição

MCMC para Hardcore Model

- Construir CM onde estados são elementos de S'
 - configurações válidas
- Fazer com que distribuição estacionária desta CM seja **uniforme**, $\pi_c = 1/Z$ para toda configuração c
- Gerar caminho amostral pela CM e usar configurações
 - X_k estado da CM no passo k → problema aqui é o tempo de mistura. Gerar & amostra máo é um problema, mas estimar a média requer muitas amostras
- Monte Carlo para estimar valor esperado

$$\hat{n}(k) = \frac{1}{k} \sum_{l=1}^k n(X_l)$$

bolhas pretas no k-ésimo estado
k-ésima config
válida

converge quando $k \rightarrow \infty$ (teorema ergódico) → $E[n(C)]$
mais distribuições $\pi_c = 1/Z$ (uniforme)

Estimador do número médio de bolinhas após k amostras

Andaremos pela cadeia e utilizaremos o teorema ergódico para gerar amostras independentes

MCMC para Hardcore Model

- Construir a CM é equivalente a definir as transições para cada estado *Dada uma configuração válida, se eu apagar uma bolinha para outra configuração*
 - cada configuração leva a outras configurações
- **Algoritmo** *Só tem transições entre vértices que diferem de 1 vértice*
 - 1) Escolher vértice v do grafo aleatoriamente
Se houver ao menos 1 vizinho preto, então o vértice vai p/ branco
 - 2) Se todos os vizinhos de v estão em 0, colocar v em 1 com probabilidade $\frac{1}{2}$; caso colocar v em 0
 - 3) Manter configuração de todos os outros vértices
- CM acima é aperiódica e irredutível, e possui distribuição estacionária uniforme
 - usar equações de reversibilidade para mostrar π

$$\pi_i P_{ij} = \pi_j P_{ji}$$

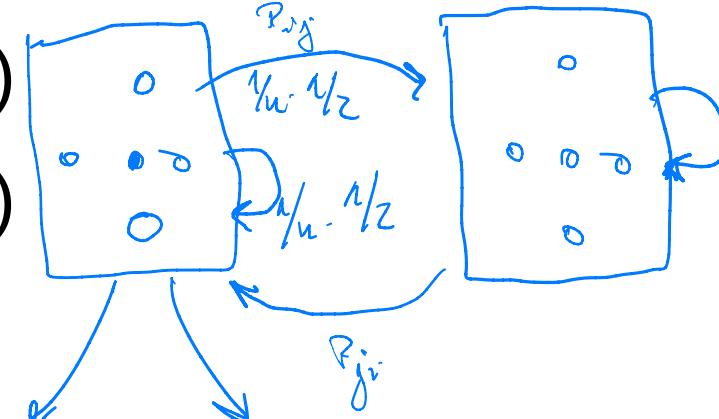
i e j são duas configurações *válidas*

Mostrando

$$\pi_i P_{ij} = \pi_j P_{ji}$$

no vértice que faz $d(i,j)=1$, todos os vizinhos do vértice branco são brancos (pois o vértice correspondente na outra configuração é preto)

- Seja i e j duas configurações quaisquer em S'
- Seja $d(i,j)$ o número de vértices em que i e j diferem
- $d(i,j) = 0 \rightarrow$ as duas configurações são idênticas (vale a relação)
- $d(i,j) > 1 \rightarrow$ não temos transições, pois apenas um vértice troca de valor por vez (vale a relação)
- $d(i,j) = 1 \rightarrow$ diferem na configuração de um único vértice v
 - vizinhos de v são todos zero, pois são válidas
 - $P_{ij} = 1/h * 1/2$ (v em 1 \rightarrow v em 0)
 - $P_{ji} = 1/n * 1/2$ (v em 0 \rightarrow v em 1)
 - Logo, $\pi_i = \pi_j = 1/Z$
 - para todos os vértices conectados



Amostragem de Gibbs

- Problema anterior é um exemplo de *Gibbs Sampling* ou *Glauber Dynamics*
 - algoritmo genérico para construção de CM para MCMC
- Considere espaço amostral S do tipo K^V onde K e V são conjuntos finitos
 - cada elemento de V assume possíveis valores de K
 - ex. anterior, $V =$ vértices do grafo, $K = \{0,1\}$
- Considere uma distribuição qualquer π sobre S
- CM construída assim a partir de X_t para o tempo $t+1$
 - 1) Escolher um elemento v de V uniformemente
 - 2) Escolher $X_{t+1}(v)$ com distribuição π condicionada em todos os outros elementos de V assumirem valor em X_t
 - 3) $X_{t+1}(w) = X_t(w)$ para todo w diferente de v

Amostragem de Gibbs

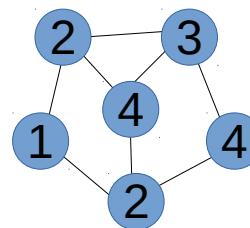
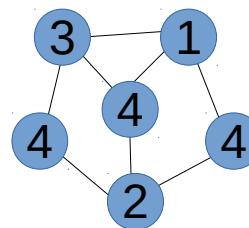
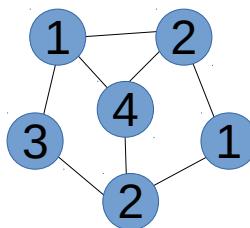
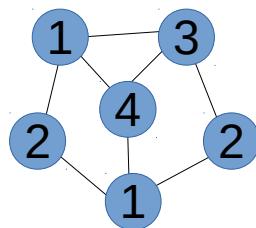
- CM de amostragem de Gibbs é aperiódica e reversível com distribuição estacionária dada por π , ou seja

$$\pi_i P_{ij} = \pi_j P_{ji}$$

- Podemos verificar propriedade acima (exercício)
- Usada para gerar amostras de S com distribuição π
- Usada para aproximar valor esperado de uma função sobre S com distribuição π
- O que é escolher novo valor a_k para $v = v_i$ com distribuição π condicionada?
 - $P[X(v_i) = a_k | X(v_1) = a_1, X(v_2) = a_2, \dots, X(v_n) = a_n]$

q -Coloração

- Uma coloração dos vértices de um grafo que usa exatamente q cores
 - vértices adjacentes tem cores diferentes
- Exemplos de 4-colorações



- **Problema:** gerar uma q -coloração para um grafo qualquer uniformemente
 - conexão com problema de coloração mínima, que é NP-Completo

Gibbs Sampler para q -coloração

- V = vértices do grafo, K = cores $\{1, \dots, q\}$
- $S = V_K$ todas possíveis colorações (incluindo não-válidas)
- *Lema:* dado uma coloração válida, a distribuição condicional das cores que um determinado vértice pode assumir é uniforme nas possíveis cores
- Algoritmo para amostragem de Gibbs, dada uma coloração válida no tempo t , X_t
 - 1) Escolher vértice v uniformemente
 - 2) Escolher $X_{t+1}(v)$ (nova cor para v) uniformemente entre as cores válidas para v em X_t
 - 3) Não modificar nenhuma outra cor: $X_{t+1}(w) = X_t(w)$
- Gerar amostra uniforme gerando caminho amostral longo o suficiente e retornando X_τ

Gibbs Sampler para q -coloração

- Gibbs Sampler anterior tem distribuição uniforme
- Considere duas colorações i e j que diferem em apenas um vértice v (único com cor diferente)
 - então $P_{ij} = P_{ji}$, pois cores válidas para v em i é igual as cores válidas para v em j
- Se i e j diferem em mais cores, então $P_{ij} = P_{ji} = 0$
- Logo, temos que

$$\pi_i P_{ij} = \pi_j P_{ji} \longrightarrow \pi_i = \pi_j = \frac{1}{Z} \quad \text{Número de colorações válidas}$$

Convergência deste Gibbs Sampler

- Considere variação onde vértice a ter cor alterada é escolhido sequencialmente (ao invés de aleatoriamente)
 - $v_1, v_2, v_3, \dots, v_n, v_1, \dots$
- Considere que $q > 2d^2$, onde d é o grau máximo de G (q é número de cores), e considere $\varepsilon > 0$
- Então, para CM definida acima, existe uma constante C (que não depende de n ou ε), tal que
$$\tau_\varepsilon = C n \log(n + \log 1/\varepsilon)$$
- CM é *fast mixing*, pois tempo de mistura é polylog em n apesar de número de estados ser exponencial
- Na prática, funciona!